

Madárfajok azonosítása hangfelvételek alapján

CNN alkalmazásával (BirdCLEF challenge)

Agócs Norbert, Magyari Zsombor, Vas Benedek Zoltán

Budapesti Műszaki és Gazdaságtudományi Egyetem

Kivonat—A jelen projekt a BirdCLEF kihívás keretében végzett deep learning alapú madárhang-osztályozási feladatot mutatja be. A cél egy olyan automatikus felismerőrendszer megvalósítása, amely rövid hangfelvételek alapján képes a madárfajok azonosítására. A megközelítés alapját a hangjelek idő-frekvencia reprezentációja és egy korszerű konvolúciós neurális hálózat (CNN) képezi.

Index Terms—Machine Learning, Deep Learning, Convolutional Neural Networks, Audio Pattern Recognition, Audio Classification, BirdCLEF, Python, Keras, TensorFlow

I. BEVEZETÉS

A madarak mindenki számára jól ismert élőlények, hiszen a Föld valamennyi élőhelyén jelen vannak. Az élőlények, így különösen a madárfajok azonosítása régóta a tudományos kutatások középpontjában áll. Míg a madarak megkülönböztetése külső megjelenésük alapján megfelelő előképzettséggel viszonylag könnyen megvalósítható, addig hangjuk alapján történő felismerésük lényegesen nagyobb kihívást jelent.

A madárhangok elemzése és azonosítása kiemelt szerepet tölt be a biodiverzitás monitorozásában, a fajok elterjedésének és vándorlási mintázatainak nyomon követésében, valamint a természetvédelmi kutatások támogatásában. A nagymennyiségű, hosszú időtartamú akusztikai felvételek feldolgozása ugyanakkor összetett feladat, amely a változó környezeti és zajviszonyok miatt robusztus és adaptív módszereket igényel. Az utóbbi években a deep learning területén elért eredmények jelentős előrelépést hoztak az automatikus hangfelismerésben. A jelen projekt célja egy konvolúciós neurális hálózaton (CNN) alapuló megközelítés bemutatása, amely alkalmas nagyleptékű madárhang-osztályozási feladatok megoldására.

II. TÉMATERÜLET ISMERTETÉSE, KORÁBBI MEGOLDÁSOK

A madárhangok automatikus felismerése régóta vizsgált problémakör a bioakusztika és a jelfeldolgozás határterületén. A deep learning módszerek megjelenése előtt a megoldások túlnyomó többsége kézzel tervezett akusztikai jellemzőkre épült, mint például a mel-frekvencia alapú cepstrális együttartók (MFCC), spektrális energiaeloszlások és időbeli statisztikák. Ezeket a jellemzőket hagyományos osztályozó algoritmusokkal – többek között support vector machines (SVM) és k-nearest neighbors (k-NN) módszerekkel – kombinálták. Bár ezek a megközelítések kontrollált környezetben elfogadható eredményeket mutattak, teljesítményük jelentősen romlott zajos, természetes hangképek esetén, valamint korlátozott volt az általánosíthatóságuk összetett mintázatokra. [1]

A konvolúciós neurális hálózatok (CNN) elterjedése alapvető szemléletváltást hozott a hangfelismerési feladatok megközelítésében. A hangjeleket kétdimenziós idő-frekvencia tartományban, elsősorban mel-spektrogramok formájában dolgozták fel. Ez lehetővé tette az audioosztályozás képfeldolgozási problémaként való kezelését. A korai CNN-alapú megoldások igazolták, hogy a tanult jellemzők robusztusabbak a háttérzajjal és a fazon belüli eltérésekkel szemben, mint a hagyományos, kézzel definiált jellemzőkre épülő módszerek [2]–[4].

A hálózatok mélységének növekedésével párhuzamosan az általános képfeldolgozás területén sikeresen alkalmazott architektúrák újítások a hangfeldolgozás területén is megjelentek. A reziduális kapcsolatokra épülő ResNet architektúra jelentősen javította a mély neurális modellek taníthatóságát és numerikus stabilitását [5], míg a sűrűn csatolt konvolúciós struktúrák hatékonyabb tanítást és a jellemzők eredményesebb felismerését tették lehetővé [6]. Ezek az architektúrák adták a nagy teljesítményű madárhang-felismerő rendszerek alapját.

Az összetett hangfelvételek feldolgozása új kihívásokat vetett fel, különösen az egymást átfedő hangesemények kezelése szempontjából. E problémák kezelésére számos tanulmány modell-egytteseken (*ensemble*) alapuló megközelítéseket, kiterjedt adatbővítési (*data augmentation*) stratégiákat, valamint célzott utófeldolgozást alkalmazott a hamis pozitív detektálások számának csökkentése érdekében [7], [8]. Az így elért eredmények rámutattak arra, hogy a rendszer teljesítményét nem kizárólag a neurális hálózati architektúra határozza meg, hanem a teljes feldolgozási lánc kulcsszerepet játszik.

A ritka madárfajok esetén tapasztalt egyenlőtlen adateloszlások kezelése érdekében a kutatások egyre nagyobb hangsúlyt helyeztek a kis mintás megközelítésekre, valamint az átvitt tanulásra (*transfer learning*). Az előre betanított modellek alkalmazása lehetővé tette egy stabilabb jellemzőtér kialakítását még kis mintás tanítóadatok esetén is [9], [10]. Ezt az irányvonalat tovább erősítették a részlegesen felügyelt tanulási módszerek (semi-supervised learning) és az álcímkezésen alapuló eljárások (*pseudo-labeling*) alkalmazása [11], [12].

A legújabb kutatások a számítási hatékonyság és a gyakorlati alkalmazhatóság javítására összpontosítanak. Ennek egyik iránya a hatékonyabb architektúrák alkalmazása, mint például az *EfficientNet* [13]. Ezzel párhuzamosan megjelentek a tokenizált spektrogram-alapú megközelítések, valamint az önfelügyelt tanulási eljárások (*self-supervised learning*), amelyek nagy mennyiségű címkézetlen adat hatékony hasznosítását teszik lehetővé [14]. Továbbá olyan módszerek is megjelentek, amelyek a frekvencia explicit beágyazásával törekednek a hasonló akusztikus motívumok megkülönböztetésére [15].

III. MÓDSZERTAN

Az alkalmazott módszertan három fő lépésből áll: a hangfelvételekből spektrogramok állítunk elő, létrehozunk egy konvolúciós neurális hálózatot, majd a spektrogramok alapján tanítjuk. A hangfelismerési feladatot képfeldolgozási problémaként kezeljük. A betanított modellt végül egy elkülönített felvételeket tartalmazó teszt adathalmazon értékeljük.

III-A. Adathalmaz

A madárfajok hangalapú azonosításának megvalósításához a BirdCLEF 2024 adathalmazt használjuk. Az adathalmaz összesen 24.459 rövid, címkézett .ogg formátumú hangfelvételt tartalmaz, amelyek 182 különböző madárfajhoz kapcsolódnak. A felvételek a Xeno-Canto adatbázisból származnak, ennek következtében a hanganyagok jelentős változatosságot mutatnak mind a környezeti zajszint, mind a felvételi minőség tekintetében. A `train_metadata.csv` fájl minden hangfelvételhez strukturált metaadatokat biztosít (Táblázat I), többek között a hangfájlhoz rendelt fajazonosítót, a felvétel készítésének földrajzi helyét, valamint a hangfájl nevét. A hangfelvételek egységes, 32 kHz-es mintavételezési frekvenciával, monó csatornán kerültek rögzítésre. Az egyes hangfájlokhoz társított madárfaj nem feltétlenül van jelen a teljes felvétel időtartama alatt, illetve nem kizárólagosan fordul elő benne.

I. táblázat
PÉLDA A `TRAIN_METADATA.CSV` ÁLLOMÁNY FELÉPÍTÉSÉRE

Mező	Típus	Példa	Leírás
primary_label	string	asbfly	Fajazonosító
type	list	[call], [song]	Hangtípus
latitude	float	39.2297	Szélesség
longitude	float	118.1987	Hosszúság
common_name	string	Asian Brown Flycatcher	Név
rating	float	5.0	Minőség
filename	string	asbfly/XC134896.ogg	Hangfájl neve

A BirdCLEF adathalmaz egy nyilvános Google Drive mappában található, ahonnan a fájlok automatikusan történik.

III-B. Adatfeldolgozás

A hangfájlok betöltése és feldolgozása a `librosa` könyvtár segítségével történik, egységes, a megadott $f_s = 32$ kHz mintavételezési frekvencia alkalmazásával. Az előfeldolgozás során minden hangfelvételt egységes, 15 másodperces hosszra alakítunk: a hosszabb felvételeket levágjuk, míg a rövidebbeket nullával töltjük fel. A nyers hangjelekből ezt követően mel-skálázott spektrogramokat állítunk elő rövid idejű Fourier-transzformáció (STFT) alkalmazásával.

A mel-spektrogram olyan idő-frekvencia ábrázolás, amely a hangjel energiájának eloszlását jeleníti meg az idő és a frekvencia függvényében, az emberi hallás frekvenciaérzékeléséhez igazított skálán. A spektrogram frekvenciatengelye hagyományosan lineáris skálán van értelmezve, azonban az emberi hallás frekvenciafelbontása nem lineáris. A Hertz- és mel-skála közötti kapcsolatot az alábbi összefüggés írja le:


$$m(f) = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right), \quad (1)$$

ahol f a frekvencia Hertzben, $m(f)$ pedig a megfelelő mel-skálázott frekvenciaérték. A frekvenciatartományt 20 Hz és 16 kHz közé korlátozzuk (emberi érzékelés tartománya), amely lefedi a madárhangok elemzése szempontjából releváns akusztikus tartományt. A kapott mel-spektrogramot decibel-skálára alakítjuk, majd mintaként normalizáljuk a $[0,1]$ intervallumba a *Min-Max* módszer alkalmazásával:

$$S_{dB} = 10 \cdot \log_{10} \left(\frac{S}{P_{ref}} \right), \quad (2)$$

$$S_{norm} = \frac{S_{dB} - \min(S_{dB})}{\max(S_{dB}) - \min(S_{dB})}, \quad (3)$$

ahol S a mel-spektrogram értéke, a $P_{ref} = 1.0$ referenciaérték. Az így előállított és normalizált mel-spektrogram rögzített méretű, kétdimenziós, 128×384 px méretű, képalapú bemenetként szolgál a konvolúciós neurális hálózat számára, lehetővé téve az idő-frekvencia mintázatok hatékony tanulását a képfeldolgozási problémaként. A madárhangok hullámformájára és mel-spektrogramjára egy példa az 1. ábrán látható.



1. ábra. Példa egy hangfelvétel hullámformájára és mel-spektrogramjára.

III-C. Neurális hálózat architektúra

A feladat megoldására a modern *EfficientNetV2* architektúrát [13] alkalmaztuk, pontosabban annak B0 variánsát. Az *EfficientNetV2* modellek célja, hogy a korábbi konvolúciós hálózatoknál gyorsabb tanítást és jobb paraméterhatékonyságot érjenek el, miközben megőrzik vagy javítják a pontosságot.

A modellünk bemenete egy $128 \times 384 \times 1$ méretű tenzor, amely a normalizált, egycsatornás mel-spektrogramot reprezentálja. Az architektúra fő építőkövei a *MBConv* (Mobile Inverted Bottleneck Convolution) és a *Fused-MBConv* blokkok. A *Fused-MBConv* blokkokat a hálózat korai szakaszaiban alkalmazzuk. Itt az 1×1 kiterjesztő konvolúciót és a 3×3 mélységi (depthwise) konvolúciót egyetlen, 3×3 konvolúcióba

vonjuk össze. Ez a hardveres gyorsítók (pl. GPU) jobb kihasználását teszi lehetővé. Az MBConv blokkokat a hálózat felső rétegeiben használjuk. Az MBConv blokkok integráns részét képezi a Squeeze-and-Excitation (SE) mechanizmus, amely a csatornák közötti függőségek modellezésével növeli a hálózat reprezentációs képességét. A modul először globális átlagolással tömöríti a térbeli információkat ('squeeze'), majd egy kétrétegű neurális háló segítségével adaptív súlyokat rendel az egyes csatornákhöz ('excitation'). Ez az eljárás lehetővé teszi, hogy a modell dinamikusan felerősítse a madárfajok azonosítása szempontjából releváns jellemzőterképeket, miközben elnyomja a kevésbé informatív, zajos csatornákat.

A hálózat felépítése 6 fő szakaszból (stage) áll, amelyek során a térbeli dimenziók csökkennek, míg a csatornák száma növekszik. A kimeneti réteg előtt egy 1×1 konvolúciót, majd *Global Average Pooling*-ot alkalmazunk, amely a térbeli dimenziókat átlagolja. Végül egy sűrű (Dense) réteg következik *Softmax* aktivációs függvénnyel, amely a 182 madárfajhoz tartozó valószínűségeket állítja elő. A modell összes tanítható paramétereinek száma 11,598,934. Egy ekkora hálózaton egy epochon át tartó tanítás T4 GPU-val nagyjából fél órát vett igénybe.

III-D. Tanítási folyamat

A modell tanítása során a teljes adathalmazt három részre osztottuk: a tanító halmaz az adatok 80%-át, a validációs halmaz és a teszt halmaz pedig 10-10%-át teszi ki. A felosztás során sztratifikált mintavételezést alkalmaztunk, biztosítva, hogy a ritka fajok aránya minden részhalmazban kiegyensúlyozott legyen.

A tanítás főbb paraméterei az alábbiak:


- **Loss függvény:** Ritka kategorikus keresztr-entropiát (Sparse Categorical Crossentropy) alkalmaztunk, mivel a célváltozóink egész számként kódolt osztálycímkék.
- **Optimalizáló:** Adam algoritmust használtunk 10^{-3} tanulási rátával.
- **Batch méret:** 32 minta lépésenként.
- **Epochok száma:** A tanítást korai leállítással (Early Stopping) felügyeltük, 5 epoch türelmi idővel (patience). Ez azt jelenti, hogy ha a validációs veszteség 5 epochon keresztül nem javul, a tanítás leáll, és a modell visszaáll a legjobb eredményt adó súlyokra.

III-E. Hiperparaméter-optimalizáció


A tanítás során a teljesítmény növelése, illetve a tanítási idő csökkentése érdekében több különböző értékkel próbálkoztunk a tanulási ráta (learning rate) paraméter esetén. Az irodalomban fellelhető ajánlások alapján logaritmikus skála szerinti lépésekben változtattuk, azonban azt találtuk, hogy az eredetitől eltérő értékek nem jelentettek értékelhető javulást.

III-F. Kiértékelés

A betanított modell teljesítményét a tanítás során nem látott teszt adathalmazon értékeltük ki. A fő mérőszámunk az osztályozási pontosság (accuracy), amely megadja a helyesen



(a) Veszteség alakulása



(b) Pontosság alakulása

2. ábra. A tanítási és validációs metrikák alakulása az epochok függvényében.

azonosított madárfajok arányát az összes tesztmintához viszonyítva. Emellett a teszt veszteséget (Test Loss) is monitoroztuk, amely a modell valószínűségi becsléseinek bizonytalanságát tükrözi. A végső kiértékeléshez a *ModelCheckpoint* által mentett, a validációs halmazon legjobb teljesítményt nyújtó modellt használtuk fel (*best_cnn.keras*).

IV. EREDMÉNYEK

A tanítási folyamatot a veszteség (loss) és a pontosság (accuracy) metrikák alapján követtük nyomon mind a tanító, mind a validációs halmazon. A tanítás menetét az 2. ábra szemlélteti.

A grafikonok alapján megállapítható, hogy a modell sikeresen tanult: a tanító veszteség (kék görbe) folyamatosan csökkent, a 16. epochra 0.5 alá esett. A validációs veszteség (sárga görbe) a 11. epoch környékén érte el a minimumát ($\approx 1,6$), ezt követően stagnálást, illetve enyhe növekedést mutatott, ami a túltanulás (overfitting) kezdetét jelzi.

A pontosság tekintetében (b) ábra) hasonló tendencia figyelhető meg: a validációs pontosság (piros görbe) a 11. epochban érte el a csúcspontját (körülbelül 63%), míg a tanító pontosság tovább növekedett, megközelítve a 90%-ot. A végső kiértékeléshez ezért a 11. epochnál elmentett súlyokat (*ModelCheckpoint*) alkalmaztuk, amely a legjobb általánosító képességet mutatta.

A független teszt halmazon végzett mérés konkrét eredményei:

- **Teszt veszteség:** 1.7061
- **Teszt pontosság:** 0.5976 (59,76%)

Az elért közel 60%-os pontosság a 182 osztályos feladat komplexitását és a terepi felvételek zajszintjeit figyelembe véve ígéretes eredmény. A teszt és a validációs eredmények közötti kis eltérés azt mutatja, hogy a választott augmentációs stratégiák segítettek a modell stabilitásának megőrzésében ismeretlen adatokon is.

V. ÖSSZEFOGLALÁS

Jelen cikkben bemutattunk egy konvolúciós neurális hálózaton alapuló rendszert, amely képes a BirdCLEF 2024 adathalmaz madárhangjainak azonosítására. A hangjeleket melspektrogrammá alakítva, képfeldolgozási feladatként oldottuk meg az osztályozást egy EfficientNetV2B0 architektúra segítségével.

Az eredmények igazolták, hogy a modern CNN architektúrák hatékonyan alkalmazhatók bioakusztikai feladatokra, még korlátozott tanítási erőforrások mellett is. A jövőbeli fejlesztések során érdemes lehet vizsgálni a zajszűrési eljárások hatását, a hosszabb hangfelvételek szegmentálási stratégiáit, valamint a transzformer alapú architektúrák (pl. Audio Spectrogram Transformer) alkalmazhatóságát a pontosság további növelése érdekében.

GENERATÍV MI ESZKÖZÖK HASZNÁLATA

A projekt megvalósítása során generatív mesterséges intelligenciát alkalmaztunk a dokumentáció elkészítésének és formázásának támogatására, valamint a Python-alapú megoldások fejlesztése során a megfelelő szintaxis és implementációs megoldások azonosításának elősegítésére.

HIVATKOZÁSOK

- [1] N. Adhikari, S. Bhattacharya, and M. Sultana, „A comprehensive survey on bird species identification models,” *International Journal of Computer Information Systems and Industrial Management Applications*, vol. 13, 2021. [Online]. Available: <https://cspub-ijcism.org/index.php/ijcism/article/view/494>
- [2] T. Grill and J. Schluter, „Two convolutional neural networks for bird detection in audio signals,” in *2017 25th European Signal Processing Conference (EUSIPCO)*, 08 2017, pp. 1764–1768.
- [3] M. Lasseck, „Audio-based bird species identification with deep convolutional neural networks,” in *Conference and Labs of the Evaluation Forum*, 2018. [Online]. Available: <https://api.semanticscholar.org/CorpusID:51941579>
- [4] S. Kahl, T. Wilhelm-Stein, H. Klinck, D. Kowerko, and M. Eibl, „Recognizing birds from sound - the 2018 birdclef baseline system,” 2018. [Online]. Available: <https://arxiv.org/abs/1804.07177>
- [5] K. He, X. Zhang, S. Ren, and J. Sun, „Deep residual learning for image recognition,” 2015. [Online]. Available: <https://arxiv.org/abs/1512.03385>
- [6] G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger, „Densely connected convolutional networks,” 2018. [Online]. Available: <https://arxiv.org/abs/1608.06993>
- [7] M. V. Conde, K. Shubham, P. Agnihotri, N. D. Movva, and S. Bessenyi, „Weakly-supervised classification and detection of bird sounds in the wild. a birdclef 2021 solution,” 2021. [Online]. Available: <https://arxiv.org/abs/2107.04878>
- [8] S. Kahl, T. Denton, H. Klinck, H. Glotin, H. Goëau, W.-P. Vellinga, R. Planqué, and A. Joly, „Overview of birdclef 2021: Bird call identification in soundscape recordings,” in *Conference and Labs of the Evaluation Forum*, 2021. [Online]. Available: <https://api.semanticscholar.org/CorpusID:237298548>
- [9] M. V. Conde and U.-J. Choi, „Few-shot long-tailed bird audio recognition,” 2022. [Online]. Available: <https://arxiv.org/abs/2206.11260>
- [10] A. Miyaguchi, J. Yu, B. Cheungvivatpant, D. Dudley, and A. Swain, „Motif mining and unsupervised representation learning for birdclef 2022,” 2022. [Online]. Available: <https://arxiv.org/abs/2206.04805>
- [11] A. Miyaguchi, N. Zhong, M. Gustineli, and C. Hayduk, „Transfer learning with semi-supervised dataset annotation for birdcall classification,” 2023. [Online]. Available: <https://arxiv.org/abs/2306.16760>
- [12] A. Miyaguchi, A. Cheung, M. Gustineli, and A. Kim, „Transfer learning with pseudo multi-label birdcall classification for ds@gt birdclef 2024,” 2024. [Online]. Available: <https://arxiv.org/abs/2407.06291>
- [13] M. Tan and Q. V. Le, „Efficientnetv2: Smaller models and faster training,” 2021. [Online]. Available: <https://arxiv.org/abs/2104.00298>
- [14] A. Miyaguchi, M. Gustineli, and A. Cheung, „Distilling spectrograms into tokens: Fast and lightweight bioacoustic classification for birdclef+ 2025,” 2025. [Online]. Available: <https://arxiv.org/abs/2507.08236>
- [15] E. R. R and C. K. Maurya, „Improving bird classification with primary color additives,” 2025. [Online]. Available: <https://arxiv.org/abs/2507.18334>